

딥페이크 진위여부 및 사용 기법 탐지 모델 DeepGuard (DeepFake + Guard)



DeepGuard

딥러닝 1조
최재우 송영준 수야다나 신여진

팀원 역할

최재우

전처리 및 모델링

수야다나

전처리 및 시각화

송영준

모델링 및 발표

신여진

모델링 및 PPT 제작

CONTENTS

- 1 주제 선정 이유
- 2 데이터 수집 및 전처리
- 3 모델링
- 4 추론 방식
- 5 평가 지표
- 6 결과 분석

01 주제 선정 이유

딥페이크 모델들이 발전하면서 AI 합성 사진들이 정교해짐에 따라 다양한 범죄가 발생하고 있음

사례 1

연예인 이정재를 사칭한 로맨스 스캠 범죄에 5억원을 사기 당한 50대



AI를 이용해 가짜 사진과 위조신분증을 제작하고
이정재를 사칭해 6개월간 5억원 갈취


사례 2

캄보디아에서 로맨스 스캠으로 약 100명에게 120억 갈취



최근 화제된 캄보디아로 사라진 2030 청년들은 스캠단지
곳곳에서 로맨스 스캠 범죄를 가담하고 있었다.
로맨스 스캠의 총책은 약 120억원을 갈취했다.

정교해지는 딥페이크 위협에 따라, 단순 탐지를 넘어 '어떤 기법'인지 파악 필요



순 탐지를 넘어 '어떤 기법'인지 파악 필요

Deepfakes

한 사람의 표정·머리 움직임은 그대로 두고,
얼굴만 다른 사람 얼굴로 바꿔 끼우는 자동인코더 방식

FaceSwap


얼굴 랜드마크와 3D 정렬로 얼굴 부분을
기하학적으로 이식하고 색/조명을 맞춰
블렌딩하는 전통적 스왑

Face2Face

A의 입·눈·볼 움직임을 추적해 B 얼굴에 그대로 복
제(신원은 B 그대로)

NeuralTextures


사람별 신경 텍스처(얼굴 질감) 모델을 학습해
새 표정·각도를 다시 렌더링 (역시 신원은 그대로,
표정만 변경)



02

데이터 수집 및 전처리

데이터 수집



FaceForensics and FaceForensics++ Dataset 외부 받은편지함 x



noreplyfaceforensics <noreplyfaceforensics@gmail.com>

나에게

10월 27일 (월) 오후 2:04 (2일 전) ☆ ↶ ⋮

Hi Choi Jae woo,

thank you for your interest in our FaceForensics and FaceForensics++ datasets.

To download the FaceForensics++ dataset please use the download script available [here](#) and consult [our github](#) for usage instructions. The original FaceForensics script can be downloaded [here](#) and you will find additional information on its [github](#).

This download script also includes the Deep Fake Detection Dataset which includes various high quality scenes of multiple actors which have been manipulated using DeepFakes.


We are also offering a benchmark on facial manipulation detection under compression which might be interesting to you under [this link](#). You can download the benchmark images [here](#).

If you have any questions, feel free to contact us under faceforensics@googlegroups.com.

NOTE: The only available server is EU2. Please execute the script with '--server EU2' for now, e.g., `python download.py --server EU2 --c c40`.

Best,
the FaceForensics authors

데이터 전처리 파이프라인




데이터 전처리 결과




	category	category_key	video_id	mp4_path	sharpness	edge_density	highfreq	blockiness	sat_mean	v_std	t_ssim
0	Real (FF++ youtube)	Real_FF_youtube	864	/content/drive/MyDrive/datasets/ffpp_c40/origi...	275.152781	0.048983	0.580272	1.013158	0.486275	0.198649	0.843943
1	Real (FF++ youtube)	Real_FF_youtube	394	/content/drive/MyDrive/datasets/ffpp_c40/origi...	245.691666	0.056588	0.697199	1.075523	0.173273	0.271914	0.848822
2	Real (FF++ youtube)	Real_FF_youtube	776	/content/drive/MyDrive/datasets/ffpp_c40/origi...	997.131177	0.100038	0.712897	1.465499	0.530275	0.221262	0.612879

03 모델링

모델 파이프라인



모델 아키텍처



학습전략

Task1

Real/Fake Binary Classification

- L_{rf}
= BCEWithLogitsLoss($\hat{y}_{rf}$, y_{rf})
- 모든 샘플에 대해 계산
- Real: $y_{rf} = 0$, Fake: $y_{rf} = 1$

Task2

Method Classification 4- way

- L_{method}
= CrossEntropyLoss($\hat{y}_{method}[fake_mask]$, $y_{method}[fake_mask]$)
- Real 샘플 제외 (기법 레이블 없음)
- Fake 샘플만 선택 (약 40~60% 배치)
- 4-way 분류 수행

ResNet 모델 설명



네트워크의 일부 층을 건너뛰어 입력 정보를 다음 층으로 직접 전달함으로써, 학습 과정에서 정보 손실을 줄이고 매우 깊은 네트워크도 효과적으로 학습할 수 있게 함

장점

1. 깊은 네트워크도 안정적으로 학습 가능
2. 빠른 수렴과 일반화 성능 향상
3. 다양한 아키텍처와 쉽게 결합 가능

단점

1. 모델이 복잡해지고 메모리 사용량 증가
2. 잘못된 shortcut 설계 시 성능 저하 가능
3. 구조가 어려워 디버깅 어려움 있음



파인튜닝 본체

```
def __init__(self, backbone_name: str = "resnet34", num_methods: int = 4):
    super().__init__()
    # 사전학습 ResNet으로 이미지 특징 추출
    self.backbone = timm.create_model(
        backbone_name,
        pretrained=True,
        num_classes=0 # feature vector만 얻기
    )
    feat_dim = self.backbone.num_features

    # 진위 분류 헤드 (이진)
    self.head_rf = nn.Linear(feat_dim, 1)
    # 기법 분류 헤드 (multi-class)
    self.head_method = nn.Linear(feat_dim, num_methods)

def forward(self, x):
    feat = self.backbone(x) # (B, F)
    logit_rf = self.head_rf(feat) # (B, 1)
    logit_method = self.head_method(feat) # (B, num_methods)
    return logit_rf, logit_method
```

- “pretrained ResNet34를 새로운 Task로 full fine-tuning”

04 추론방식

프레임별 예측

프레임 추출

- 테스트 영상에서 일정 간격으로 프레임 추출 또는 전체 프레임 사용
- 각 프레임을 멀티태스크 모델에 개별 입력

```
def extract_frames_from_video(  
    video_path: str,  
    out_dir: str,  
    frames_per_video: int = 8,  
    face_detector=None,  
) -> int:
```

프레임별 예측 - 단위 예측

Task1 - 진짜/가짜 분류

- 출력: 시그모이드 확률(0~1)
- 기준:
- $\geq 0.5 \rightarrow \text{Fake(가짜)}$
- $< 0.5 \rightarrow \text{Real(진짜)}$

Task 2 — 조작 기법 분류

- 출력: 4개 조작 기법에 대한 소프트맥스 확률 벡터
- 예측: 확률이 가장 높은 클래스 선택

영상별 예측 집계

Task1 - 진짜/가짜 분류

모든 프레임의 Fake 확률 평균값 계산

- 결정:
- $\geq 0.5 \rightarrow$ 영상 = Fake
- $< 0.5 \rightarrow$ 영상 = Real

Task 2 (영상이 Fake일 경우에만 수행)

- 프레임들의 소프트맥스 확률 벡터 평균
- 평균 확률이 가장 높은 조작 기법 선택
(연속 확률을 활용하기 위해 다수결(majority vote) 대신 평균 사용)

프레임 예측의 잡음 제거 및 안정화를 위해 평균 투표(average voting) 사용

추론방식

두 작업(Task)의 종속 관계

- Task 1 결과가 Task 2를 결정
- 영상 = Real → Task 2 결과는 무시 또는 N/A
 - 영상 = Fake → Task 2 조작 기법 제공

실제 서비스 흐름과 동일

1. 영상이 Fake인지 판단
2. Fake라면 어떤 조작 기법인지 분석

최종 출력

하나의 영상 = N개의 프레임의 집계 결과
최종 영상 단위 예측으로 평가 지표 계산

05

평가 지표 설정

평가 지표 설정

Task1

- Accuracy
- F1-score (불균형 데이터 고려)

Task 2

- Macro F1-score (모든 클래스 평균)
- Confusion Matrix

joint 5-Class Accuracy (종합 성능)

실험 결과 - Task 1

- Accuracy > 95%, F1-score > 0.95 달성.
- 일반화 성능 확보 (Unseen data에서도 잘 작동)

exp_name	model	optimizer	batch_size	epochs	best_val_acc	best_val_f1
E1_sgd_bs32	multitask	sgd	32	8	0.8506	0.9191
E2_sgdm_bs32	multitask	sgd_momentum	32	8	0.8483	0.9179
E3_adam_bs32	multitask	adam	32	8	0.8483	0.9179
E4_adam_bs16	multitask	adam	16	8	0.8483	0.9179
E5_adam_bs64	multitask	adam	64	8	0.8483	0.9179

실험 결과 - Task 2

- Macro F1 = 0.2 (Random Guess 수준)
- 기법 분류 실패. 특정 클래스로 쏠리거나 혼동함

	precision	recall	f1-score	support
Real	0.00	0.00	0.00	65
Deepfakes	0.50	0.08	0.14	72
FaceSwap	0.28	0.73	0.40	90
Face2Face	0.21	0.27	0.24	64
NeuralTextures	0.24	0.10	0.14	63
accuracy			0.27	354
macro avg	0.25	0.24	0.18	354
weighted avg	0.25	0.27	0.20	354

=== Confusion matrix ===

```
[[ 0  1 45 10  9]
 [ 0  6 45 17  4]
 [ 0  1 66 20  3]
 [ 0  2 42 17  3]
 [ 0  2 39 16  6]]
```


샘플 이미지에 대한 실험 결과



자체 제작 딥페이크 이미지

Preprocessing

Model Inference

Aggregation


Fake probability : 0.679
Predicted is_fake : True
Predicted method: FaceSwap
Method probs : [0.24 0.28 0.24 0.21]



```
/content/TEAM01_Deepfake
Image: /content/data/deepfake/Deepfakes/sample.jpg
Fake probability : 0.679
Predicted is_fake: True
Predicted method : FaceSwap
Method probs      : [0.24942207 0.28732952 0.2445962  0.2186522 ]
```

06 결과 분석

실패 원인 분석 - 데이터 관점



- 기법들이 모두 "얼굴 합성"을 기반
- 시각적 차이 미미 → 구분 어려움
- 저해상도/압축 프레임에서 더욱 심각

조작기법 간 분리는 품질지표만으로는 약함

각각이 별도 트레이스로 들어 있지만(범례에 각 이름 존재), 3D 공간에서 뚜렷하게 떨어진 “섬”처럼 떨어지지 않는.

실패 원인 분석

모델 관점

- Pretrained 된 ResNet-34 모델이 ImageNet 기반
→ Face Forencis ++ 데이터와 도메인 차이 발생

학습설계 관점

- Fake 샘플만 Task2 손실 계산 (~60% 배치)
- Real 샘플 제외 (~40% 배치)
- Task2가 상대적으로 약한 학습 신호
- Task1 성능 개선이 전체 손실 주도

향후 개선 방향

구조 변경

2-Stage 모델로 분리 (탐지 모델 → 분류 모델)하여 간섭 제거

입력 데이터

주파수(Frequency) 도메인 변환 활용 (DCT, FFT 등)

추가 정보

Facial Landmarks 등 기하학적 정보 활용

Q&A